



ESCUELA POLITÉCNICA NACIONAL



Proyecto I BIM
Sistema de Recuperación de la Información

DOCENTE: Ing. Carrera Iván.

Integrantes del Grupo:

Bolaños Toro Luis Elias
Silva Herrera Sonia Elizabeth
Suárez Herrera Andrés Salvatore

Paralelo:
GR1CC

INGENIERÍA EN COMPUTACIÓN

Período 2025-A



ESCUELA
POLITÉCNICA
NACIONAL

Facultad de Ingeniería en Sistemas
Recuperación de la Información

Proyecto I BIM

Sistema de Recuperación de la Información

Ing. Carrera Iván.

Semestre 2025-A

Índice

1. Objetivo.....	3
2. Introducción.....	3
Descripción del Corpus Utilizado.....	3
Explicación de las decisiones de diseño	3
Ejemplos de consultas y resultados	4
Métricas de evaluación	4
2. Conclusiones y Recomendaciones.....	5
3. Bibliografía	6



ESCUELA
POLITÉCNICA
NACIONAL

Facultad de Ingeniería en Sistemas Recuperación de la Información

Proyecto I BIM

Sistema de Recuperación de la Información

Ing. Carrera Iván.

Semestre 2025-A

1. Objetivo

- Desarrollar e implementar un sistema de recuperación de información eficiente y evaluable, basado en modelos vectoriales como TF-IDF, que permita responder consultas en lenguaje natural sobre un corpus temático real, facilitando el acceso a documentos relevantes de manera ordenada y precisa.

2. Introducción

Descripción del Corpus Utilizado

El corpus utilizado para el desarrollo de este proyecto, es el corpus CQADupstack Gaming, parte del benchmark BEIR (Benchmarking IR); un subconjunto del benchmark CQADupStack. Está diseñado para tareas de investigación en recuperación de información y clasificación de preguntas duplicadas dentro de plataformas de tipo *community question answering*.

Este conjunto de datos proviene de los foros de StackExchange, específicamente del subforo *gaming.stackexchange.com*; donde los usuarios formulan preguntas relacionadas con videojuegos, estrategias, mecánicas y recomendaciones. CQADupStack incluye 12 subforos de StackExchange con datos previamente procesados a partir del *data dump* oficial liberado el 26 de septiembre de 2014. El objetivo del dataset es permitir la evaluación robusta de sistemas automáticos para recuperación de preguntas similares o duplicadas en foros comunitarios. El corpus consta de aproximadamente 45.000 documentos, los cuales fueron sometidos a un proceso de preprocesamiento que incluye: tokenización, eliminación de stopwords, lematización y normalización.

Explicación de las decisiones de diseño

El diseño del sistema de recuperación de información se fundamentó en satisfacer los requisitos funcionales mínimos establecidos en el proyecto, que incluyen la construcción de un índice, la implementación de modelos de recuperación, una interfaz de consulta y la evaluación de resultados mediante métricas estándar.

Para la construcción del índice, empleamos el corpus temático *CQADupStack-Gaming*, el cual fue cargado a partir de archivos .jsonl, estructurados text, title, id, y url.

Luego, para el procesamiento el sistema ejecuta un pipeline de limpieza textual, que incluye: tokenización con expresiones regulares, usando `regex_tokenize`; normalización, eliminación de stopwords con NLTK, y Lematización.

Se implementó la lógica del modelo TF-IDF, permitiendo el acceso rápido a la frecuencia

de términos en documentos. Este enfoque también se extiende al modelo BM25, tal como nos pedía en los requerimientos.



Para el diseño del modelo de recuperación se construyó un vectorizador `TfidfVectorizer`. A partir de la matriz resultante, se calcula la similitud coseno entre la consulta vectorizada y cada documento del corpus. Esta implementación permite el ranking de documentos ordenados por relevancia. El usuario puede enviar cualquier cadena de texto como consulta. El sistema la preprocesa siguiendo el mismo pipeline que los documentos del corpus, y luego la compara con todos los documentos utilizando la métrica seleccionada.

Los resultados se devuelven en formato JSON ordenados por puntuación, incluyendo fragmentos relevantes del documento (preview) y su score de similitud.

Luego, para la interfaz el backend ofrece una API REST (Flask) que puede ser consultada desde Postman, navegador o desde el frontend. Para pruebas directas, también se desarrolló una interfaz CLI temporal (`test_queries.py`) donde el usuario puede: ingresar consultas manualmente y, ver en pantalla los resultados ordenados.

Por último, para la evaluación de resultados, se utilizó el archivo `qrels` para evaluar los resultados, que contiene pares `query-id – corpus-id` marcados como relevantes (`score = 1`).

Ejemplos de consultas y resultados



Métricas de evaluación

```
TERMINAL PORTS

Documentos procesados: 45301
Umbral usado: 0.1
Resultados finales: 20
Mejor similitud: 0.4390

=====

RESULTADOS FINALES:
Precision promedio: 0.0298
Recall promedio: 0.4583
MAP: 0.2412

El análisis resumido con ejemplos se
ha guardado en: evaluacion_resultad
os_20250609_004729.txt
eliasbolanos@MacBook-Air-de-Elias ba
ck %
```

```
back > E evaluacion_resultados_20250609_004729.txt
```

1							
2							
3							
4	TABLA RESUMEN DE RESULTADOS						
5							
6							
7	Query ID	Precision	Recall	AP	Relevantes	Recuperados	Coincidencias
8							
9	176	0.0500	0.5000	0.2500	2	20	1
10	236	0.0000	0.0000	0.0000	1	20	0
11	392	0.2500	1.0000	0.8267	5	20	5
12	400	0.0500	1.0000	1.0000	1	20	1
13	428	0.0500	1.0000	0.1250	1	20	1
14	517	0.0000	0.0000	0.0000	2	20	0
15	648	0.0500	1.0000	1.0000	1	20	1
16	904	0.0500	1.0000	1.0000	1	20	1
17	1345	0.0500	1.0000	0.0769	1	20	1
18	1724	0.1000	1.0000	0.8333	2	20	2
19	1727	0.0500	1.0000	0.0833	1	20	1
20	1793	0.0500	1.0000	1.0000	1	20	1
21	1878	0.0500	1.0000	0.5000	1	20	1
22	2151	0.0500	1.0000	0.3333	1	20	1
23	2900	0.0000	0.0000	0.0000	2	20	0
24	2908	0.0500	1.0000	1.0000	1	20	1
25	3040	0.1000	1.0000	1.0000	2	20	2
26	3492	0.0500	1.0000	1.0000	1	20	1
27	3597	0.0500	0.5000	0.0714	2	20	1
28	4116	0.0500	1.0000	1.0000	1	20	1
29	4235	0.0500	1.0000	0.3333	1	20	1
30	4300	0.0500	1.0000	1.0000	1	20	1
31	4491	0.0000	0.0000	0.0000	1	20	0
32	4550	0.0500	1.0000	1.0000	1	20	1
33	4656	0.0500	1.0000	0.7500	1	20	1

```
EJEMPLO 1: QUERY 400

-----

Texto de query: How to map mutliple keys to a button in Half Life 2/Team Fortress 2?

MÉTRICAS: Precision=0.0500, Recall=1.0000, AP=1.0000

TOP 5 DOCUMENTOS RECUPERADOS:
1. [✓ RELEVANTE] How can I bind keys in Team Fortress 2?
2. [x NO RELEVANTE] Import Half-Life Save Into Half-Life: Source
3. [x NO RELEVANTE] Are Blue Shift and Opposing Force "canon"?
4. [x NO RELEVANTE] Can you play Half-Life 2 without steam?
5. [x NO RELEVANTE] What was the Vortigaunt's motivation?

-----

EJEMPLO 2: QUERY 648

-----

Texto de query: Where can I find the pet dog in Fallout 3?

MÉTRICAS: Precision=0.0500, Recall=1.0000, AP=1.0000
```

2. Conclusiones y Recomendaciones

Conclusiones:

- Se implementó exitosamente un sistema de recuperación de información funcional, capaz de responder consultas en lenguaje natural.
- La integración de TF-IDF con similitud coseno permite recuperar documentos relevantes de forma precisa y ordenada.

Recomendaciones:

- Experimentar con un corpus más grande, para comprobar si los resultados serían los mismos, o se debería tener en cuenta otro diseño o arquitectura.

3. Bibliografía

- [1].Hoogeveen, D., Verspoor, K. M., & Baldwin, T. (2015). *CQADupStack: A Benchmark Data Set for Community Question-Answering Research*. In Proceedings of the 20th Australasian Document Computing Symposium (pp. 3:1–3:8). ACM. <https://doi.org/10.1145/2838931.2838934> Available at: <https://github.com/D1Doris/CQADupStack>